

第八届中国研究生人工智能创新大赛

知识超图驱动的复杂学术查询智能搜索系统

(ScholarGraph)

项目文档

版本号: V1.0

日期: 2026.08.31

团队名称: Dong

目 录

目录

1	项目概况	1
1.1	背景和基础	1
1.2	场景和价值	1
1.3	所需支持	2
2	项目规划	2
2.1	整体目标	2
2.2	技术创新点	3
3	实施方案	4
3.1	技术可行性分析	4
3.2	技术细节	4
3.3	计划和分工	8
	参考资料	8

记录更改历史

序号	更改原因	版本	作者	更改日期	备 注
1	按官方模板完成项目文档	V1.0	Dong	2026.08.31	初赛提交稿

1 项目概况

本章说明项目的立项背景、应用价值与资源条件，回答本工作要解决的真实问题，并交代已有的工程基础。

1.1 背景和基础

文献检索是科研工作流中最基础也最耗时的环节。研究者面对的往往不是简单的关键词查找，而是细粒度、多维度的复杂研究问题，例如“为使用合成数据增强监督微调的思路寻找高质量、多样化的顶刊论文”。这类查询要求系统理解查询的语义意图，具备多轮检索、引文网络探索与跨文献关联推理的能力，远超传统搜索引擎词面匹配的边界。赛题将这一问题列为研究方向，正是因为它代表了学术信息获取的真实需求。

近年来，以大语言模型为核心的智能搜索 Agent 在该方向展现出明显潜力。PaSa 采用双 Agent 架构并以强化学习优化，在真实查询基准 RealScholarQuery 上召回率超过 Google 与 GPT-4o 组合基线 37.78 个百分点 [1]；SPAR 以查询分解与演化在 AutoScholar 上取得 $F_1 = 0.38$ [2]；Ai2 Paper Finder 凭借多索引语义检索与多臂老虎机采样策略，在科学评测套件上大幅领先通用 Agent [3]。该方向的评测与探索还包括面向文献检索的基准 LitSearch [5]、组合检索与语言模型的 Demonstrate-Search-Predict [6]，以及面向科学问答的语言 Agent [4]。然而，对 PaSa、SPAR 与 Ai2 Paper Finder 三个系统的源码级分析表明，它们收敛于同一范式：由大模型理解查询、多源召回，再以启发式规则排序，排序信号不外乎相关性、权威性与时间的组合。三者均未构建或利用论文之间的结构化知识——例如“这篇论文改进了那篇”“这两个方法同属一个族”。而这类结构恰恰是回答“拓展研究思路”类查询的关键：用户需要的不是相似度排名，而是知识演化的脉络。

本项目针对上述空白构建。团队在知识图谱与超图抽取方向已有扎实的前期积累：已建成 2300 余篇学术论文的全文解析管线（基于 MinerU 结构化解析 [7]）、自演化模式库（schema）的抽取内核（事务性知识库，64 项单元测试覆盖），以及跨机器学习、生物、流体力学、分子动力学四个学科领域的域无关抽取验证。本地 sci-evo 论文获取与解析服务提供从 DOI 到 PDF 再到结构化全文的完整自持链路。参赛系统即在此基座上构建。

1.2 场景和价值

本系统的核心场景是研究者的文献调研工作流，可细分为三类典型任务。在综述起步场景中，研究生进入新领域时需要快速获得该领域的代表性论文与知识脉络，系统的结构化归纳输出——方法演化链与方法族分组——直接提供可阅读的知识地图，而非孤立的论文列表。在深度追踪场景中，研究者希望了解某一方法的改进谱系，例如某方法有哪些后续改进；系统为每条引用标注 extends、improves、compares 等意图类别，使查询可沿语义化的引文链精确导航，而非无差别遍历整个引文网络。

在跨文献关联推理场景中，当查询涉及多篇论文之间的关系比较时，超图中的方法族与概念共现结构提供超出字面相似度的关联信号。

就社会价值而言，学术检索效率直接影响科研产出效率。现有工具（包括商业学术搜索引擎）均停留在“匹配”层面，无法完成“理解”层面的任务。本系统展示了一条可行路径：将检索过程中积累的知识结构化为可复用的资产，使系统随使用持续增强。这一范式对医疗文献、专利、法规等垂直领域的智能检索具有直接的迁移价值。

从竞争格局看，学术搜索赛道的现有产品大致分为三代：以 Web of Science、Google Scholar 为代表的传统引文索引以关键词匹配为核心；以 Semantic Scholar、Consensus 为代表的 AI 增强搜索加入了语义匹配；以 PaSa、SPAR 及本系统为代表的新一代 Agent 搜索正在解决意图理解与知识推理。本系统在第三代中占据明确的差异化位置，是唯一以结构化知识资产（知识超图）为核心设计要素的系统。

1.3 所需支持

项目实施所需的算力与数据资源均已自备，无额外的算力、硬件或培训需求。大模型推理通过 Paratera API 完成，其中 DeepSeek-V4-Flash[8] 用于信息抽取与判断，qwen3-embedding[9] 用于语义重排，按量计费，单查询成本约 0.01 至 0.02 元人民币。论文全文的获取与解析由本地 sci-evo 服务承担（MinerU 引擎），不依赖外部算力。检索后端对接 Semantic Scholar[10]、OpenAlex[11]、Crossref[12] 三家学术 API 的免费配额，符合赛题的技术要求。开发与实验均在单台工作站完成，无集群需求。

2 项目规划

本章给出参赛期间的整体目标，并通过与参考系统的对比调研论证项目的主要技术创新点。

2.1 整体目标

参赛期间的整体目标是交付一个可运行、可评测、可演示的端到端学术搜索系统，并在公开评测集上建立系统的量化证据。具体而言，在功能层面，系统实现赛题要求的全流程能力——查询理解与分解、多源多策略检索、论文综合排序、结果的归纳整理与结构化展示，并以一键命令入口交付；在评测层面，系统在 SPARBench 练习集 [13]（50 查询）上建立完整的证据链，涵盖迭代改进记录与关键设计的消融实验；在知识资产层面，系统构建并交付一张持久化的领域知识超图，作为结构化输出的展示载体。三个层面的目标均已达成或进入最终验证阶段，详见第 3 章。

2.2 技术创新点

创新点的论证建立在对三个参考系统的源码级对比之上。表 1 从检索源、是否利用论文间结构化知识、排序信号与引文利用方式四个维度给出对比。

表 1 与现有学术搜索系统的对比

对比维度	PaSa	SPAR	Ai2 Paper Finder	本系统
检索源	Google 爬取	五源检索	多索引 +MAB	免费学术 API+超图
利用论文间结构化知识	否	否	否	是（知识超图）
排序信号	相关性（RL 学习）	相关性 + 启发式	相关性 + 权威 +MAB	语义 + 权威 + 结构关联
引文利用方式	全链路遍历	引用链迭代	无专门机制	意图感知选择性导航

在检索源上，PaSa 依赖 Google 爬取，SPAR 依赖五源检索，Ai2 Paper Finder 依赖多索引与多臂老虎机采样；本系统在免费学术 API 的资源约束下，以超图提供的结构化信号弥补检索能力的差距。在是否利用论文间结构化知识上，三个参考系统均未构建此类知识，排序信号不外乎相关性、权威性与时间的组合；本系统将知识超图作为一等公民融入检索全流程。在引文利用方式上，PaSa 与 SPAR 均以遍历或迭代方式利用引文，本系统则以引用意图标注实现选择性导航。基于上述差距，本项目的主要技术创新点归纳为以下四项。

创新点一：知识超图深度参与检索全流程。现有系统的排序均为相关性、权威性、时间的启发式组合，未引入论文间的结构化关系。本系统在检索的三个环节注入结构化知识信号：查询理解阶段的概念变体扩展（超图经跨论文合并学到的领域词汇）、排序阶段的结构化关联推理，以及输出阶段的可溯源知识归纳。知识超图在检索过程中增量生长——对判分为高相关的论文自动建图——检索行为沉淀为持久的知识资产而非一次性消耗，这是与会话式系统的本质区别。实证层面，系统已建成 50 篇论文的领域图（3827 个概念节点、3912 条超边），检索探索图另累积 122 篇种子论文。

创新点二：引用意图感知的选择性引文导航。PaSa 依赖强化学习（每查询平均约 382 次交互）学习“应深入哪篇引文”，训练成本高且不可解释。本系统以引用意图标注直接回答该问题：每条引文关系被分类为 extends、improves、compares、replaces、adapts、background 六类，“找改进”类查询沿 improves 边精确导航。引用意图抽取管线已并入主抽取内核并通过验收，语料内引用图 16 条边与独立验证实现完全对齐。

创新点三：自演化 schema 与离线—在线分离架构。抽取模式库随语料增量演化：离线演化出的 29 模式库相比 12 模式种子，在相同语料与相同判分条件下边召回提升 24%（808 条增至 1001 条），且模式库跨域迁移无衰退。该证据支撑“离线

演化、在线冻结”的架构设计，使在线查询不承担演化成本。

创新点四：面向效率的系统性工程设计。全流程成本自动打点，记录每次大模型与检索调用的计数、延迟与费用。快模式单查询成本 0.01 至 0.02 元、延迟 13 至 36 秒，约为 Ai2 Paper Finder 公开报告成本（0.063 美元/查询）的二十分之一。判分验证层输入瘦身 60% 与并发化、引用意图分类并发化（4 倍加速）等优化均有实测支撑。

3 实施方案

本章论证项目的技术可行性，给出系统总体架构与核心技术设计的实验证据，汇总各基准上的推理效果指标，并说明计划与分工。

3.1 技术可行性分析

可行性从数据获取、行业知识获取与算力成本三方面论证。

数据获取方面，检索源经过如实的可用性审计。Semantic Scholar 匿名 bulk 端点（词项匹配、无相关性排序）是唯一覆盖 arXiv 预印本的可用源；其 API key 申请未获批、常规检索端点限流，OpenAlex 匿名池触发日级封禁——这些约束均被实测记录并纳入架构，而非回避。Crossref 提供权威被引元数据，但其对 arXiv-only 论文存在结构性覆盖缺失。一项关键的量化诊断表明：SPARBench 零命中查询的标准答案中，87% 本可被 Semantic Scholar 检索到（用答案自身标题词探测），说明瓶颈在查询措辞而非源收录，这直接决定了本系统“以结构化知识改写查询”的技术路线（见 3.2 节）。论文全文的获取通过本地 sci-evo 服务完成（DOI 到 PDF 再到结构化解析），单篇约 1 至 3 分钟，已有 2300 余篇的存量处理能力。

行业知识获取方面，系统的领域知识不依赖人工标注，而通过增量建图自动积累：每篇论文经抽取管线（分节规划、抽取、验证、提交四阶段）转化为概念节点、模式边与引用意图边，全部携带可溯源的证据原文。该过程已在四个学科领域验证了域无关性。

算力与成本方面，全部实验与开发在单台工作站完成。大模型调用按量计费，整个参赛期间的开发与实验总成本预计不超过 100 元人民币；单查询推理成本见 2.2 节创新点四。系统各环节均有磁盘缓存与断点续跑设计，长时任务（如 50 篇领域建图）可无人值守完成。

3.2 技术细节

系统总体架构分为四层。查询理解层完成意图解析、多维约束识别（主题、方法、时间、发表场所）与子查询分解，生成三类改写变体。多源召回层并行查询三家学术 API 并合并去重，形成数千篇候选池，随后经语义重排层选取判分窗口。综合排序层由大模型对候选做高度相关、部分相关、不相关三档判分，输出按语义与

权威混合分排序。归纳整理层按查询意图组织结构化输出。知识超图横跨四层提供支持，详见创新点一。以下论证三个核心技术设计，每个设计均附实验证据与预期指标。

设计一：语义重排层解决“收录但找不到”问题。诊断实验发现了现有检索管线的一个关键损耗源：Semantic Scholar 的 bulk 检索端点返回无相关性排序的候选流，最极端的实测案例中，被引超过三万次的领域经典论文处于匹配集内，却因随机采样从未进入返回页，任何召回策略都会随机丢失关键论文。语义重排层对候选池全量计算语义相似度后，此类问题被系统性消除。注入实验的验证结果为：将 5 篇目标论文混入 85 篇混合候选池，重排后 3 篇进入前十（第 3、7、10 位）。该设计已在全部后续实验中启用。

设计二：分块判分与摘要辅助输入解决判分精度问题。判分环节的两个工程问题均通过对照实验定位并解决。其一为注意力稀释：150 篇候选整列提交判分时，判分器系统性遗漏窗口内的目标论文（实测 3/3 漏判），改为 50 篇分块后全部命中。其二为泛标题盲视：标准答案中大量论文采用泛化标题，纯标题判分实测 7/12 的在池答案被误判为不相关，将摘要引入判分输入后该盲区显著缓解。输出排序的信号选择经三臂消融实验（纯语义、混合、纯权威）验证存在查询类型依赖性：在 10 查询诊断集上，纯语义排序使气候类具体查询 F_1 提升 200%，但综述类查询下降 67%，两类信号命门互补，最终采用语义为主、权威为辅的混合分。50 查询全量的三臂对照在 10 题检查点显示三臂命中数完全持平（各 10 篇），端到端排序差异在该基准上不显著，按预注册止损规则中止并如实记录。

设计三：增量建图与知识超图的持续生长。系统在检索循环中对判分为高相关的论文自动增量建图（单篇 5 至 16 分钟、成本 0.05 至 0.2 元），构建过程包含分节抽取、跨论文概念对齐合并、引用意图标注三个阶段，全部通过事务性内核提交，具备原子性、可重放与完整审计日志。知识图以命名图形式持久存储、跨查询会话累积。当前已建成 50 篇 LLM 领域论文的领域图：3827 个概念节点、3912 条超边（概念结构边 3750 条、引用意图边 162 条），模式层 218 个；检索过程的探索图另累积 122 篇种子论文并随使用持续生长。基于该图的结构化归纳输出（方法演化链、方法族分组、逐边证据溯源）是结构化展示评分项的直接支撑。系统结构化输出的实际界面如图 1-3 所示。

各基准上的推理效果指标汇总于表 2。

在 SPARBench[13] 上，证据分两条线如实呈现。诊断线（10 查询诊断集）的 $\text{set-}F_1$ 从 0.007 迭代至 0.093，用于逐层定位覆盖、排序、判分三处病灶。泛化线（50 查询全量）的基线 $\text{micro-}F_1$ 为 0.035。本轮以超图 schema 驱动的查询生成在独立验证集上，将召回池答案覆盖率提升 30.4 个百分点（开发集）与 16.7 个百分点（留出集），判据预注册、留出复核以防过拟合。50 查询全量的全机制栈终跑在 10 题检查点与基线命中数持平后，按预注册止损规则中止：召回池的覆盖增益真实存在，但漏斗逐层对冲，端到端增益在该开发基准上未确立，覆盖增益的最终裁决移交官方基准。每一轮改进均有单变量消融归因，负结果（排序臂的查询类型依赖性、图信号经大模型中间层的稀释）同样如实记录。




图 1 搜索主界面：召回、判分、排序、建图四阶段管线实时推进，结果按相关度分档并带被引数与年份展示




图 2 知识图探索器： 枢纽节点表示 n-ary 超边，边色区分引用意图（background、adapts、compares 等），图例可按意图开关



图 3 证据溯源面板：点击概念节点，右栏展开其定义、来源论文、相关实体与证据原文，实现逐条结论可回溯

表 2 系统推理效果与效率指标

基准与口径	本系统	对照（均为对应基准已发表数字）
SPARBench 50 查询（micro- F_1 ）	0.035（基线）	单 API+LLM 形态第一；同源 S2+LLM 为 0.014[2]
SPARBench 10 查询诊断集（set- F_1 ）	0.007→0.093	诊断迭代链，用于病灶定位
AutoScholarQuery 留出集（micro- F_1 @5）	0.150	已发表 S2+LLM 基线 0.0044，为其 34 倍 [2]
RealScholarQuery（recall@20， $n=3$ ）	0.186	Google+GPT-4o 为 0.202，PaSa 为 0.580[1]
快模式延迟 / 成本	13-36 秒 / 0.01-0.02 元	Ai2 Paper Finder 约 \$0.063/查询 [3]

在官方族基准 RealScholarQuery (PaSa 论文的真实查询基准, 50 查询、平均 15.8 篇标准答案/查询) 上, 因提供商限流而中止的首轮运行完成 3 个查询, $\text{micro set-}F_1@20$ 为 0.185、 $\text{recall}@20$ 为 0.186 (样本量 $n = 3$ 如实标注)。同口径对照下, 本系统 $\text{recall}@20$ 达到最强 Google 基线 (Google 与 GPT-4o 组合, 0.202) 的 92%, 高于 Google Scholar (0.151), 与 PaSa-7b (0.580) 仍有差距 [1]。该差距源于资源形态: 本系统无 Google 检索、无 API key、仅用单一免费源加超图, 却达到 Google 量级召回。SPARBench 上已量化的覆盖缺口诊断 (标准答案 87% 在源内可达、败于查询措辞) 指明了后续机制迭代的方向。效率指标方面, 快模式单查询延迟 13 至 36 秒、成本 0.01 至 0.02 元; 深模式 (含增量建图) 增加数分钟至数十分钟与相应成本, 两种模式覆盖从交互式检索到深度调研的完整场景。

3.3 计划和分工

参赛期间的项目计划按三个阶段推进。第一阶段 (已完成) 为基础能力建设, 包括抽取内核、检索管线、评测框架与全链自持的论文获取服务。第二阶段 (已完成) 为系统集成与评测闭环: 知识超图并入检索全流程, 完成 SPARBench 全量评测与消融实验体系。第三阶段 (进行中, 截止前完成) 为最终验证与交付打磨, 包括全量评测数据的最终确认、结构化输出展示实例、参赛文档与演示视频制作、代码包整理。

本项目由本人独立完成, 按阶段承担全部工程角色。抽取内核与知识超图构建、检索管线与评测框架、系统集成与文档制作均由同一人贯通, 这保证了架构决策 (如图信号走直连路径、不经大模型中间层) 在设计、实现、评测三处的一致性。

参考资料

参考文献

- [1] He Y, Huang G, Feng P, et al. PaSa: An LLM Agent for Comprehensive Academic Paper Search. ACL 2025. arXiv:2501.10120.
- [2] Shi X, Li Y, Kou Q, et al. SPAR: Scholar Paper Retrieval with LLM-based Agents for Enhanced Academic Search. arXiv:2507.15245, 2025.
- [3] Feldman S, et al. AstaBench: Rigorous Benchmarking of AI Agents with a Scientific Research Suite. ICLR 2026. arXiv:2510.21652.
- [4] Skarlinski M, et al. Language Agents for Answering Questions from Scientific Literature. NeurIPS 2024.
- [5] Ajith A, Xia M, Chevalier A, et al. LitSearch: A Retrieval Benchmark for Scientific Literature Search. EMNLP 2024. arXiv:2407.18940.

- [6] Khattab O, et al. Demonstrate-Search-Predict: Composing Retrieval and Language Models for Knowledge-Intensive NLP. arXiv:2212.1404, 2022.
- [7] OpenDataLab. MinerU: 一站式开源 PDF 数据提取工具. <https://github.com/OpendataLab/MinerU>, 2024.
- [8] DeepSeek. DeepSeek 开放平台 API. <https://platform.deepseek.com>, 2026.
- [9] Qwen Team. Qwen3-Embedding. <https://github.com/QwenLM/Qwen3-Embedding>, 2025.
- [10] Semantic Scholar Team. The Semantic Scholar Open Research API. <https://api.semanticscholar.org>, 2026.
- [11] OpenAlex. OpenAlex: The Open Catalog to the Global Research System. <https://openalex.org>, 2026.
- [12] Crossref. Crossref REST API. <https://api.crossref.org>, 2026.
- [13] 赛题官方. SPARBench 练习基准数据集（赛题三配套）, 2026.